

Proposition de sujet de thèse

Ludovic Andrieux

11 juin 2025

Modélisation multi-fidélité des ballottements d'ergols dans les réservoirs de lanceurs spatiaux par hybridation de modèles analytiques, CFD et réseaux de neurones informés par la physique.

Mots-clés

Ballottements d'ergols, réservoirs spatiaux, CFD, modèles pendulaires, PINN, simulation GNC, ECSS/SMP

Profil et compétences recherchées

- Diplôme d'ingénieur ou Master 2 en aérospatial ou data science appliquée.
- Compétences en mécanique des fluides, simulation numérique (CFD), méthodes de modélisation réduite (modèle masse-ressort, pendule).
- Intérêt ou expérience en machine learning physique (PINN, PIML).
- Maîtrise du langage C++ et/ou Python, familiarité avec les standards ECSS/SMP appréciée.

Présentation du projet doctoral

Les réseaux de neurones informés par la physique, ou Physics-Informed Neural Network (PINN) constituent un nouveau paradigme de l'apprentissage profond, capable de résoudre à la fois des problèmes directs et inverses pour des Equations aux Dérivées Partielles (EDP) non linéaires [8]. En intégrant des contraintes physiques sous-jacentes dans l'architecture d'un réseau de neurones à propagation avant, ou Feedforward Neural Network (FFNN), les PINNs peuvent être entraînés comme modèle de substitution avec peu ou pas de données étiquetées pour l'inférence de solutions d'EDP [3]. Dans la littérature actuelle, l'implémentation des PINNs est envisagée à la fois comme complément et comme alternative potentielle aux techniques numériques existantes, dans un large éventail de domaines de recherche en sciences et en ingénierie [6, 1, 2].

Contexte

Le comportement des ergols dans les réservoirs de lanceurs spatiaux a un impact direct sur la stabilité du vol, la performance des algorithmes de contrôle de vol, et la réussite

de la mission. Lors des phases propulsées, les effets dynamiques des masses ballottantes peuvent être modélisés efficacement à l'aide de pendules équivalents (voir par exemple [4]), mais ces modèles deviennent limités dès que le régime d'accélération devient trop faible (et même inopérant en micro-gravité), le mouvement des masses ballottantes trop important, ou encore le comportement diphasique dominant.

Problématique

Dans un contexte de simulation numérique, notamment dans un cadre de validation et de qualification du contrôle de vol, il est essentiel de disposer de modèles à la fois précis, rapides et adaptables, capables de représenter les phénomènes physiques à différentes échelles et dans différents contextes de vol. Les approches actuelles peinent à fournir un cadre générique, rapide et fiable pour modéliser les ballottements d'ergols dans toutes les phases de vol. La CFD offre des résultats précis mais coûteux, les modèles réduits (typiquement les modèles de pendules) sont efficaces lors des phases propulsées mais sous des conditions d'angles de ballottements relativement faibles, tandis que les réseaux de neurones informés par la physique (PINN) offrent un compromis prometteur entre précision et coût.

Objectifs

Cette thèse vise à développer un cadre générique de modélisation du comportement des ergols dans les réservoirs, intégrant plusieurs niveaux de fidélité, et exploitable dans des environnements industriels standards (simulation tout numérique ou avec éléments réels), en mettant l'accent sur les cas pour lesquels des modélisations réduites ne sont pas disponibles (micro-gravité et en phase propulsée hors représentativité des modèles pendulaires).

Les objectifs principaux sont :

1. Développer une architecture logicielle C++ modulaire :
 - Modèles pendulaires et masse-ressorts,
 - Modèles CFD (sur la base des codes CFD utilisés pour la constitution du jeu de données),
 - Intégration de modèles PINN/PIML,
 - Interopérabilité avec les standards ECSS/SMP.
2. Explorer, comparer et synthétiser les méthodes de modélisation des ballottements :
 - Approche analytique (petits angles, linéaires, pendules),
 - Simulation numérique CFD (gaz compressible et liquide avec interface libre, évaporation et transfert thermique, extraction d'efforts sur les parois),
 - Réseaux de neurones informés par la physique (PINN) et opérateurs neuronaux (NOet PINO).
3. Proposer une stratégie de sélection de modèle selon :
 - Le niveau de fidélité requis,
 - Les contraintes de simulation,
 - La phase de vol et l'environnement.

Approche méthodologique

La thèse s'appuiera sur une approche structurée en trois volets :

1. La modélisation physique et numérique du problème de mécanique des fluides, dans le but de définir des cas tests (accélérations constantes, transitoires, micro-gravité) et les mettre en œuvre pour, d’une part, caractériser les modèles analytiques (pendulaires et/ou masses-ressorts), et, d’autre part, constituer le jeu de données pour les modèles neuronaux.

Une approche incrémentale est envisageable pour enrichir la modélisation au fur et à mesure d’une montée en complexité des phénomènes à prendre en compte lors de l’implémentation :

- système gaz-liquide incompressible et interface libre,
 - compressibilité du gaz et représentativité des sources (représsurisation et écoulement sortant),
 - transfert thermique et changement de phase.
2. Le développement de modèles complets (CFD), réduits (pendule), de substitution (PINN ou PIML), et hybrides selon les standards ECSS/SMP pour une intégration dans un environnement industriel qui assurent une bonne portabilité dans différents environnements de simulation.
 3. L’évaluation des performances sur le compromis précision / rapidité à l’aide d’intégration des modèles dans un simulateur numérique boucle fermée et établissement de recommandations pour le choix de modèle selon l’usage.

Démarche envisagée

Période	Étape
Semestre 1	Revue bibliographique, construction des cas tests et formulation mathématique du problème
Semestre 2	Simulations CFD, extraction de données, premiers prototypes PINN
Semestre 3	Développement de la librairie modulaire, intégration PINN, pendules et CFD
Semestre 4	Évaluation, benchmarks, stratégie de sélection de modèle
Semestre 5	Intégration dans simulateurs, benchmarks
Semestre 6	Finalisation, soutenance, dépôt logiciel si applicable

TABLE 1 – Planning prévisionnel des étapes du projet

Apports scientifiques et industriels

Des outils d’évaluation à la fois rapides et réalistes de modélisation d’ergols dans les réservoirs de lanceurs spatiaux sont attendus.

Cette approche synthétique a pour objectif de mieux cerner les domaines de validité, les interactions et les complémentarités entre modèles analytiques, simulations CFD et techniques de Machine Learning

Plus spécifiquement, un apport direct est attendu en ce qui concerne la modélisation du phénomène physique. Typiquement :

- Une modélisation réduite des ballottements en micro-gravité : où l’état de l’art ne fournit pas de modèle réduit qui soit utilisable dans un environnement couplé avec des algorithmes GNC, contrairement aux phases sous accélération.

- L’initialisation des modèles pendulaires après une phase orbitale : où l’état actuel des connaissances nous pousse à tirer aléatoirement cet état initial. On cherche alors à réduire ces conservatismes.
- La mise en œuvre de modèles lors des phases de retournement des lanceurs réutilisables : où la dynamique du lanceur peut avoir un impact sur celle des ballottements qui fait sortir du domaine d’applicabilité des modèles pendulaires.

Un apport direct sur le déroulement d’un projet de développement de lanceur est aussi attendu, avec la capacité de simuler à l’aide de modèles ML des cas complets qui sont généralement simulés par couplage CFD tard dans le déroulement du projet.

Enfin, au travers de l’intégration dans un environnement industriel, on estime que le gain opérationnel sera non négligeable.

Bibliographie indicative

- [1] Stefano BUOSO, Thomas JOYCE et Sebastian KOZERKE. « Personalising Left-Ventricular Biophysical Models of the Heart Using Parametric Physics-Informed Neural Networks ». In : *Medical Image Analysis* 71 (juill. 2021), p. 102066. ISSN : 13618415. DOI : [10.1016/j.media.2021.102066](https://doi.org/10.1016/j.media.2021.102066). URL : <https://linkinghub.elsevier.com/retrieve/pii/S1361841521001122> (visité le 04/04/2025).
- [2] Shengze CAI et al. « Physics-Informed Neural Networks for Heat Transfer Problems ». In : *Journal of Heat Transfer* 143.6 (1^{er} juin 2021), p. 060801. ISSN : 0022-1481, 1528-8943. DOI : [10.1115/1.4050542](https://doi.org/10.1115/1.4050542). URL : <https://asmedigitalcollection.asme.org/heattransfer/article/143/6/060801/1104439/Physics-Informed-Neural-Networks-for-Heat-Transfer> (visité le 04/04/2025).
- [3] Salvatore CUOMO et al. « Scientific Machine Learning Through Physics-Informed Neural Networks : Where We Are and What’s Next ». In : *Journal of Scientific Computing* 92.3 (26 juill. 2022), p. 88. ISSN : 1573-7691. DOI : [10.1007/s10915-022-01939-z](https://doi.org/10.1007/s10915-022-01939-z). URL : <https://doi.org/10.1007/s10915-022-01939-z> (visité le 06/05/2025).
- [4] Raouf A. IBRAHIM. *Liquid Sloshing Dynamics : Theory and Applications*. Cambridge New York Melbourne Madrid Cape Town Singapore São Paulo : Cambridge University Press, 2005. 1 p. ISBN : 978-0-521-83885-6 978-0-511-53665-6. DOI : [10.1017/CB09780511536656](https://doi.org/10.1017/CB09780511536656).
- [5] Xihaier LUO et al. *A Machine Learning-based Characterization Framework for Parametric Representation of Nonlinear Sloshing*. 25 jan. 2022. DOI : [10.48550/arXiv.2201.11663](https://doi.org/10.48550/arXiv.2201.11663). arXiv : [2201.11663 \[cs\]](https://arxiv.org/abs/2201.11663). URL : <http://arxiv.org/abs/2201.11663> (visité le 04/04/2025). Prépubl.
- [6] Zhiping MAO, Ameya D. JAGTAP et George Em KARNIADAKIS. « Physics-Informed Neural Networks for High-Speed Flows ». In : *Computer Methods in Applied Mechanics and Engineering* 360 (1^{er} mars 2020), p. 112789. ISSN : 0045-7825. DOI : [10.1016/j.cma.2019.112789](https://doi.org/10.1016/j.cma.2019.112789). URL : <https://www.sciencedirect.com/science/article/pii/S0045782519306814> (visité le 06/05/2025).

- [7] Ashkan RAFIEE, Fabrizio PISTANI et Krish THIAGARAJAN. « Study of Liquid Sloshing : Numerical and Experimental Approach ». In : *Computational Mechanics* 47.1 (jan. 2011), p. 65-75. ISSN : 0178-7675, 1432-0924. DOI : [10.1007/s00466-010-0529-6](https://doi.org/10.1007/s00466-010-0529-6). URL : <http://link.springer.com/10.1007/s00466-010-0529-6> (visité le 07/04/2025).
- [8] M. RAISSI, P. PERDIKARIS et G. E. KARNIADAKIS. « Physics-Informed Neural Networks : A Deep Learning Framework for Solving Forward and Inverse Problems Involving Nonlinear Partial Differential Equations ». In : *Journal of Computational Physics* 378 (1^{er} fév. 2019), p. 686-707. ISSN : 0021-9991. DOI : [10.1016/j.jcp.2018.10.045](https://doi.org/10.1016/j.jcp.2018.10.045). URL : <https://www.sciencedirect.com/science/article/pii/S0021999118307125> (visité le 17/04/2024).

Collaborations envisagées

ESA, CNES, INRIA, ONERA

Laboratoire d'accueil

TBD

Acronymes

CFD Computational Fluid Dynamics. 1–4

CNES Centre National d'Études Spatiales. 5

ECSS European Cooperation for Space Standardization. 1–3

EDP Equation aux Dérivées Partielles. 1

ESA European Space Agency. 5

FFNN Feedforward Neural Network. 1

GNC Guidance, Navigation and Control. 1, 3

INRIA Institut National de Recherche en Informatique et en Automatique. 5

ML Machine Learning. 3, 4

NO Neural Operator. 2

ONERA Office National d'Études et de Recherches Aérospatiales. 5

PIML Physics-Informed Machine Learning. 1–3

PINN Physics-Informed Neural Network. 1–3

PINO Physics-Informed Neural Operator. 2

SMP Simulation Model Portability. 1–3